



# Projeto Redes Convolucionais

Grupo 47: Isis Caroline Lima Viana e Marco Antonio Oliveira Santos

Data de Entrega: 01/12/2024

## Sumário

Resumo.....	3
Introdução.....	4
Metodologia.....	4
Preparação dos Dados.....	4
Implementação do Algoritmo de Redes Convolucionais.....	5
Resultados.....	6
Métricas de Avaliação.....	6
Visualizações.....	6
Discussão.....	7
Conclusão e Trabalhos Futuros.....	8
Referências.....	9

## Resumo

O presente relatório descreve o desenvolvimento de um modelo de classificação de imagens baseado em Redes Neurais Convolucionais (CNNs) para distinguir entre imagens de indivíduos masculinos e femininos. As etapas incluíram a preparação e normalização dos dados, a definição de uma arquitetura neural eficiente, e a avaliação utilizando métricas como acurácia e perda. Os resultados indicaram que o modelo obteve um pouco de overfitting apresentando uma perda de 80%, contudo seu desempenho foi satisfatório com uma acurácia também de 80%. No fim, este trabalho reforçou a importância de uma preparação adequada dos dados e o impacto de arquiteturas personalizadas para problemas específicos, além da eficácia de redes convolucionais para problemas dessa natureza.

# Introdução

Reconhecer imagens com inteligência artificial (IA) é crucial em diversos setores devido à capacidade de interpretar, analisar e tomar decisões com base em dados visuais.(ABRACD, 2024). O reconhecimento de rostos humanos é uma aplicação amplamente utilizada em segurança, como em sistemas de vigilância que identificam indivíduos em tempo real para acesso controlado, identificação de suspeitos e monitoramento em áreas públicas. Além disso, essa tecnologia é empregada em dispositivos pessoais, como smartphones, para desbloqueio por reconhecimento facial, oferecendo segurança e conveniência (GEO Sem Fronteiras, 2024). Redes Neurais Convolucionais (CNNs) têm se mostrado particularmente eficazes nesse domínio, devido à sua capacidade de aprender representações hierárquicas diretamente a partir dos dados visuais, sem a necessidade de engenharia manual de características.

Este projeto foca no desenvolvimento de uma CNN para resolver o problema de classificação de gênero em imagens. O projeto foi desenvolvido completamente do zero e sem auxílio de bibliotecas que já fazem tudo sozinhas (sem utilizar transfer learning). Devido a isso o grupo pode compreender melhor como funciona uma CNN, desde as camadas convolucionais até técnicas de regularização. Além de aprender a personalizar a arquitetura de um modelo a fim de que ele se encaixe melhor no problema que deve resolver.

## Metodologia

### Preparação dos Dados

Primeiro utilizou-se o colab “Ponto de partida” para se importar o Dataset CUFS. Em seguida observou-se a saída ao printar as imagens. Na plataforma da trilha no moodle foi requerido que todas as imagens fossem rotuladas, contudo são escolhidas ao acaso 188 novas imagens toda vez que se roda o programa. Então para que ainda assim fosse possível rotular os dados criou-se uma função que analisa os nomes das imagens. Convenientemente, cada imagem foi salva com um nome iniciado com a letra m para as fotos de pessoas do sexo masculino e com a letra f para pessoas do sexo feminino. Nisso, rotulou-se as imagens como 0 para homens e 1 para mulheres.

Em seguida, para garantir um melhor desempenho da rede, ajustou-se as imagens para que todas seguissem um mesmo padrão. Na teoria isso facilitaria o trabalho da rede convolucional

para reconhecer padrões. Esse ajuste resumiu-se a redimensionar todas as imagens para um tamanho uniforme de 250x200 pixels (altura x largura) e colocá-las em preto e branco (normalizando o RGB das imagens até que elas estivessem dentro do intervalo [0, 1]).

Por fim, dividiu-se o conjunto das imagens em 3 conjuntos: 50% para o treinamento, 30% para validação, e 20% para teste.

## **Implementação da Rede Convolutacional**

### **1. Construção do modelo**

Foram criadas 3 camadas com ReLU e MaxPooling, uma camada Flatten para achatar os dados antes da camada densa, a camada densa totalmente conectada com 128 neurônios e uma camada de saída sigmoid binária (para classificar a entrada como 0 ou 1).

### **2. Treinamento do Modelo**

Foi utilizado um otimizador Adam com função de perda `binary_crossentropy`. E 20 épocas com batch size 32.

## **Avaliação dos resultados**

O modelo foi testado com o conjunto de teste e seu desempenho foi medido a partir dos parâmetros perda e acurácia. Em seguida foram plotados dois gráficos mostrando cada um dos parâmetros respectivamente ao longo dos períodos do treinamento.

## **Ajuste do modelo**

Observou-se que existe uma quantidade relevante de overfitting no modelo então buscou-se formas de aprimorá-lo como o Early Stopping, contudo os resultados finais ficaram ainda mais distorcidos utilizando esses métodos então optou-se por deixar o modelo do jeito que estava

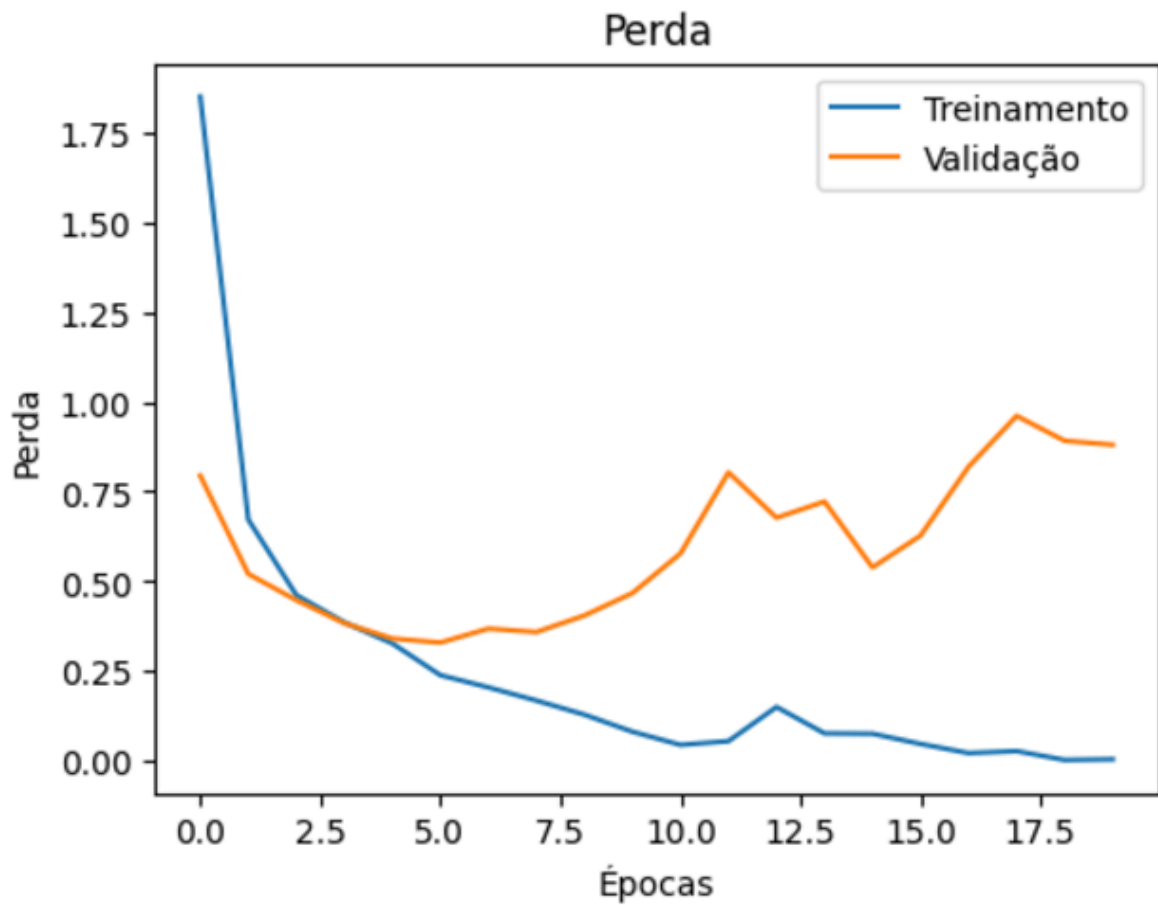
# Resultados

## Métricas de Avaliação


- Acurácia do teste: 0.8421
- Perda do teste: 0.8895

## Visualizações

### 1. Perda ao longo do treinamento



## 2. Acurácia ao longo do treinamento



## Discussão

Os resultados indicam que o modelo apresenta sinais de overfitting, ou seja, ele aprendeu excessivamente as características do conjunto de treinamento, comprometendo seu desempenho ao ser avaliado no conjunto de teste. Apesar disso, a acurácia obtida foi de 80%, o que é um resultado positivo e indica que o modelo tem uma boa capacidade preditiva.

Em resumo, o modelo é capaz de realizar boas previsões, embora ainda cometa erros com uma frequência maior do que o ideal.

## Conclusão e Trabalhos Futuros

Em conclusão, este projeto demonstrou a eficácia das redes convolucionais na classificação de imagens. Entre os principais aprendizados, destacam-se a relevância da preparação adequada dos dados e o impacto das escolhas realizadas no desempenho do modelo.

Para aprimorar a rede, recomenda-se aumentar a quantidade e a diversidade do dataset, além de explorar outras técnicas de regularização, como dropout e batch normalization.



## Referências

Introdução a Redes Neurais Convolucionais e Classificação de Imagens – ABRACD – ASSOCIAÇÃO BRASILEIRA DE CIÊNCIA DE DADOS. [S. l.], 2024. Disponível em: <https://abracd.org/introducao-a-redes-neurais-convolucionais-e-classificacao-de-imagens-aula-de-50-min/>. Acesso em: 30 nov. 2024.

GEO Sem Fronteiras, Website. **Processamento Digital de Imagem: Sob a Perspectiva do Mundo Moderno**. [S. l.], 2024. Disponível em: <https://geosemfronteiras.org/blog/processamento-digital-de-imagem-sob-a-perspectiva-do-mundo-moderno/>. Acesso em: 30 nov. 2024.

Documentação do TensorFlow: <https://www.tensorflow.org/>

Fontes de dados: Face Sketch Database. Disponível em: <https://www.kaggle.com/datasets/arbazkhan971/cuhk-face-sketch-database-cufs/data>